

Media secuencial

$$\hat{\mu}_{t+1} = \hat{\mu}_t + \frac{1}{N} (x_{t+1} - \hat{\mu}_t).$$

Media normal

$$\hat{\mu}_{MLE} = \frac{1}{N} \sum_{i=1}^N x_i$$

Varianza secuencial

$$\hat{\sigma}_{t+1}^2 = \hat{\sigma}_t^2 + \frac{1}{N} [(x_t - \hat{\mu})^2 - \hat{\sigma}_t^2].$$

Varianza normal

$$\hat{\sigma}_{MLE}^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{\mu})^2$$

Softmax:

$$\pi(a = j \mid s) = \frac{e^{\beta a_j}}{\sum_{i=1}^k e^{\beta a_i}}$$

Derivada softmax con respecto a la acción elegida

$$\frac{\partial S_j}{\partial a_j} = S_j(1 - S_j)$$

Derivada softmax con respecto a la acción no elegida

$$\frac{\partial S_j}{\partial a_i} = -S_j S_i$$

Actualización de parámetros para datos discretos

$$a_j \leftarrow a_j + \alpha(1 - s_j) R$$

$$a_i \leftarrow a_i + \alpha(0 - s_i) R$$

para $i \neq j$

- s_j es la probabilidad actual de la acción j .

Q learning

$$Q_{k+1}(s, a) = Q_k(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

- **γ** : descuento del future - Indica cuánto valen las recompensas futuras.
 - Si γ es **alto** (≈ 1):
el agente es paciente \rightarrow valora el futuro.
 - Si γ es **bajo**:
el agente solo se preocupa por recompensas inmediatas.

Valor esperado

$$\mathbb{E}[f(X)] = \sum_i p(x_i) \cdot f(x_i)$$

Decaimiento exponencial de ϵ

$$\text{eps_threshold} = \text{eps_end} + (\text{eps_start} - \text{eps_end}) * \exp(- \text{steps} / \text{eps_decay})$$

- Con probabilidad $1 - \epsilon$, el agente **explota**: elige la acción con el valor Q más alto.
- Con probabilidad ϵ , el agente **explora**: elige una acción aleatoria entre las disponibles.

PDF de una distribución normal

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$